

Propuesta de Negocio

TP Integrador — Analítica Descriptiva | Actividad 1: Análisis Exploratorio de Datos y Contextualización de Negocio

1. Descripción del dataset y fuentes consultadas

Dataset propio construido mediante Web Scraping del portal MercadoLibre Inmuebles, con cobertura de la Ciudad Autónoma de Buenos Aires, homologado a un esquema de columnas propio y consolidado en un dataframe maestro en Pandas.

Estado actual del dataset: 65.846 avisos (56.553 de venta y 9.293 de alquiler), sin duplicados por identificador ni por link. De ese total, 55.582 corresponden a inmuebles residenciales (Departamento, PH y Casa) y 10.264 a inmuebles comerciales (Oficina, Local), estos últimos fuera del alcance de este proyecto (Sección 8).

Distribución por tipo de propiedad: Departamento 45.222, PH 6.060, Local 5.935, Oficina 4.329, Casa 4.300.

Cobertura de variables clave: identificación, operación, tipo, título, precio, moneda, link y fecha de scraping, 100%; dirección publicada 99,89%; barrio publicado 99,80%; latitud/longitud 99,89%; superficie total 99,63%; superficie cubierta 97,12%; baños 95,70%; antigüedad 97,06%; expensas 93,76%. El detalle de variables con menor cobertura y su tratamiento se documenta en la Sección 7.

Tipos de datos capturados: textuales (dirección, barrio, título), numéricos (precio, superficie, antigüedad, ambientes, coordenadas), ordinales/categoricos (tipo de propiedad, tipo de vendedor, disposición, orientación, estado del inmueble) y dicotómicos (18 variables de amenities y condiciones: admite mascotas, apto crédito, apto profesional, amoblado, ascensor, balcón, terraza, patio, pileta, parrilla, SUM, gimnasio, laundry, seguridad, aire acondicionado, calefacción, lavadero y dormitorio en suite).

La cobertura de coordenadas (99,89%) es la pieza central de esta propuesta: habilita un enriquecimiento geoespacial punto a punto —no solo por barrio— con fuentes externas del Gobierno de la Ciudad, para calcular distancia real a transporte público, seguridad, salud y educación por cada aviso individual (Secciones 4 y 12).

2. Contexto y situación de negocio (interlocutor)

Nuestra consultora de tecnología inmobiliaria fue contratada por un inversor rentista de perfil buy-to-rent: un inversor particular / family office con capital disponible (rango estimado USD 80.000–250.000) que busca comprar inmuebles usados en CABA, ponerlos en alquiler tradicional y sostenerlos en cartera 5–10 años, maximizando la renta neta mensual y la potencial revalorización del capital.

Hoy el cliente decide en base a recorridas manuales de portales y al criterio de un asesor inmobiliario tradicional, sin cuantificar de forma rigurosa la relación entre precio de compra y renta de alquiler esperada por zona y tipología, y sin poder incorporar de forma sistemática variables de entorno como la cercanía real a transporte, seguridad, salud o educación. No tiene forma de comparar barrios entre sí, de detectar unidades subvaluadas, ni de priorizar en qué avisos concretos invertir su tiempo de búsqueda activa entre decenas de miles de publicaciones.

3. Preguntas clave según los 4 niveles de análisis

Descriptivo

- ¿Cuál es el precio promedio y mediano por m² de venta y de alquiler en cada barrio de CABA?
- ¿Cómo se distribuyen los inmuebles publicados por tipología (departamento, PH, casa), ambientes, antigüedad y superficie?
- ¿Qué proporción de las publicaciones ofrece amenities, cochera, aire acondicionado, seguridad, etc.?

Diagnóstico

- ¿Por qué ciertos barrios muestran una rentabilidad bruta más alta que otros?
- ¿Existe relación entre el nivel de expensas y la rentabilidad neta?
- ¿Qué atributos (amenities, cochera, apto crédito) explican mejor las diferencias de precio dentro de una misma zona?
- ¿La distancia real a transporte público, la cantidad de delitos, la cercanía a centros de salud, a establecimientos educativos o a espacio verdes explica parte de la variación de precio dentro de un mismo barrio?
- ¿Las publicaciones de vendedores particulares muestran patrones de precio distintos a las de inmobiliarias?

Predictivo

- ¿Es posible estimar el precio "justo" de venta o alquiler de una propiedad a partir de sus características (m², ambientes, barrio, amenities, antigüedad, entorno geoespacial)?
- ¿Se puede anticipar qué zonas mejorarán su rentabilidad relativa a partir de variables exógenas (tipo de cambio, nuevas líneas de transporte)?

Prescriptivo

- ¿En qué barrios y tipologías debería priorizar la búsqueda el inversor para maximizar la rentabilidad bruta esperada, dado un presupuesto determinado?
- ¿Qué combinación de atributos —incluyendo entorno geoespacial— maximiza el ROI de una inversión a valor actual?
- Dado el universo completo de avisos activos, ¿cuál es el ranking priorizado de oportunidades concretas (no solo de zonas) sobre el que el inversor debería actuar primero? — respondida directamente por el Score de Oportunidad de Inversión (Sección 4).

4. KPIs — definición matemática y comercial

El Índice de Sobre/Subvaluación funciona como eje narrativo del proyecto: no alcanza con saber cuánto rinde una inversión, también hay que saber si se está pagando de más o de menos por ella al momento de la compra. Se suman cuatro KPIs de entorno geoespacial —posibles gracias a la cobertura de coordenadas del dataset— y el Score de Oportunidad de Inversión, que cierra el circuito llevando todo el diagnóstico a un ranking accionable por aviso individual.

KPI	Fórmula	Lectura comercial
Rentabilidad Bruta Estimada	$(\text{Alquiler Mensual Prom. Zona} \times 12) / \text{Precio de Venta Prom. Zona}$	Años de alquiler bruto necesarios para repagar la compra, sin descontar gastos.
Rentabilidad Neta Estimada	$((\text{Alquiler Mensual Prom.} \times 12) - (\text{Expensas Prom.} \times 12) - \text{Mantenimiento Est.}) / \text{Precio de Venta Prom.}$	Ajusta la rentabilidad bruta por costos recurrentes de tenencia.
Índice de Sobre/Subvaluación (KPI central)	$(\text{Precio Real} - \text{Precio Predicho por modelo de zona} + \text{antigüedad} + \text{amenities}) / \text{Precio Predicho}$	Negativo = posible oportunidad de compra por debajo de mercado. Eje narrativo del proyecto.

KPI	Fórmula	Lectura comercial
Payback Period (años)	1 / Rentabilidad Neta Estimada	Años para recuperar la inversión inicial vía renta.
Tasa de Confort/Amenities	Nº de amenities presentes (de 15 relevadas: amoblado, ascensor, balcón, terraza, patio, pileta, parrilla, SUM, gimnasio, laundry, seguridad, A/C, calefacción, lavadero, dormitorio en suite) / 15	Proxy de calidad constructiva de la unidad, calculable directamente sobre el dataset actual.
Precio por m² (venta / alquiler)	Precio Total / Superficie (m²)	Permite comparar unidades de tamaños distintos entre sí.
Distancia a subte (m)	Distancia geodésica (Haversine) entre las coordenadas del aviso y la estación de subte más cercana	Proxy de conectividad calculado por aviso individual, no por promedio de barrio. Insumo directo de H4.
Índice de Colectivos de Entorno	Densidad de colectivos en un radio de 500 metros alrededor del aviso	Proxy de conectividad calculado por aviso individual, no por promedio de barrio. Insumo directo de H4.5
Índice de Seguridad de Entorno	Densidad de hechos delictivos en un radio de 1000 metros alrededor del aviso	Proxy de seguridad percibida a nivel de cuadra/manzana, más preciso que la variable barrio. Insumo directo de H5.
Índice de Educación de Entorno	Densidad de establecimientos educativos en un radio de 500 metros alrededor del aviso	Proxy de accesibilidad educativa, especialmente relevante para unidades de 3+ ambientes con perfil familiar. Insumo directo de H7.
Índice de Educación de Entorno	Densidad de establecimientos educativos en un radio de 500 metros alrededor del aviso	Proxy de accesibilidad educativa, especialmente relevante para unidades de 3+ ambientes con perfil familiar. Insumo directo de H7.
Índice de Espacios Verdes de Entorno	Densidad de espacios verdes en un radio de 1000 metros alrededor del aviso	Proxy de cercanía a espacios verdes, especialmente relevante para unidades de 3+ ambientes con perfil familiar. Insumo directo de H7.
Score de Oportunidad de Inversión	$(0,4 \times \text{Rentabilidad_Neta_norm} + 0,4 \times \text{Subvaluación_norm}) \times \text{Factor_Confianza}$, donde $\text{Factor_Confianza} = 1,0$ (sin anomalías detectadas, $\text{Flag_Anomalia_General} = 0$), $0,6$ (con alguna anomalía no crítica) o 0 — se descarta del ranking — si el aviso tiene datos críticos faltantes o coordenadas fuera de CABA	Ranking único (0-100) por aviso individual que prioriza la búsqueda activa del inversor, apoyado en el propio sistema de control de calidad del dataset.

El Score de Oportunidad de Inversión no reemplaza a los KPIs de diagnóstico: los combina. La rentabilidad indica cuánto rinde una inversión; el Índice de Subvaluación indica si se paga de más o de menos por ella; el Score responde la pregunta que el cliente realmente hace — "¿en cuál invierto mi tiempo de búsqueda hoy?" — apoyado en el propio sistema de flags de calidad ya calculado sobre el dataset (Sección 6), sin depender de una segunda fuente de datos para confiar en el resultado.

5. Hipótesis iniciales

- **H1:** la rentabilidad bruta estimada es significativamente mayor en barrios del sur y oeste de CABA (p. ej. Flores, Parque Avellaneda, Mataderos) que en barrios premium del norte (Palermo, Recoleta, Belgrano), porque el precio de venta cae más que proporcionalmente respecto al alquiler.
- **H2:** la presencia de amenities y cochera incrementa el precio de venta por m² más de lo que incrementa el alquiler por m², reduciendo la rentabilidad bruta relativa de las unidades "premium" dentro de un mismo barrio.
- **H3:** los monoambientes y 2 ambientes tienen una rentabilidad bruta estimada mayor que las unidades de 3+ ambientes, porque la demanda de alquiler unipersonal/parejas sostiene precios de alquiler proporcionalmente más altos por m².

- **H4:** la distancia geodésica a la estación de subte más cercana, calculada a partir de las coordenadas de cada aviso, correlaciona negativamente con el precio de venta por m², controlando por barrio.
- **H4.5:** la densidad geodésica a la estación de subte más cercana, calculada a partir de las coordenadas de cada aviso, correlaciona negativamente con el precio de venta por m², controlando por barrio.
- **H5:** la densidad de hechos delictivos en su entorno inmediato correlaciona negativamente con el precio de venta por m², controlando por barrio y amenities — como proxy de percepción de seguridad a nivel de cuadra.
- **H6:** las publicaciones de vendedores particulares (Tipo_Vendedor) tienen mayor probabilidad de estar subvaluadas (Índice de Sobre/Subvaluación negativo) que las publicadas por inmobiliarias, porque el vendedor particular suele tener menor información de mercado y, en algunos casos, mayor urgencia por concretar la venta.
- **H7:** la densidad de establecimientos educativos y de puntos verdes (escuelas y parques) correlaciona negativamente con el precio de alquiler por m² en unidades de 3+ ambientes en mayor medida que en monoambientes, porque las familias con hijos —perfil típico de esas unidades— priorizan la cercanía a la escuela y a espacios verdes al momento de alquilar.
- **H8:** la distancia geodésica al centro de salud más cercano, calculada a partir de las coordenadas de cada aviso, correlaciona negativamente con el precio de venta por m², controlando por barrio.

6. Ejecución técnica de la extracción de datos

Fuente: MercadoLibre Inmuebles, operaciones de venta y alquiler, Capital Federal. La búsqueda se recorrió combinando operación × tipo de propiedad × barrio, en lugar de un único listado general, porque el sitio limita la cantidad de páginas navegables dentro de una misma búsqueda; recorrer por barrio y tipo evita quedarse corto de resultados en las categorías más numerosas.

Arquitectura resumible en dos etapas. Una etapa de descubrimiento de links (por página de resultados) y una etapa de detalle (por aviso), cada una con checkpoint propio persistido en JSON, de forma que un corte en cualquier punto se retoma exactamente donde quedó. Un archivo de lock evita que dos ejecuciones corran en simultáneo y pisen sus propios datos.

Deduplicación en dos niveles. Cada aviso se deduplica por Item_ID y, adicionalmente, por Link canónico, tanto al descubrir enlaces como al guardar el detalle — resultado verificado: 0 duplicados por Item_ID y 0 por link sobre los 65.846 registros finales.

Desafío — bloqueos y captchas. Se implementó un detector doble de protecciones: por texto visible en la página (frases como "verificá que sos humano", "unusual traffic", "acceso denegado") y por patrones en el HTML (marcas de reCAPTCHA, Cloudflare challenge, px-captcha). Ante cualquier señal, la ejecución se corta de forma segura y guarda el avance en lugar de seguir extrayendo contenido de una página de desafío que ensuciaría el dataset.

Desafío — fichas incompletas. Antes de aceptar el detalle de un aviso se exige que tenga título, precio y al menos 3 atributos extraídos; si no los tiene, se reintenta hasta 3 veces con espera creciente antes de descartarlo. Los finales de paginación reales (HTTP 404/410) se reconocen como tales y no consumen el límite de errores consecutivos que sí corta la ejecución ante un problema genuino.

Guardado incremental y atómico. Los avisos nuevos se guardan cada 50 registros mediante escritura atómica de CSV (archivo temporal + reemplazo), evitando archivos corruptos ante un corte a mitad de escritura.

Procesamiento y control de calidad. Sobre el CSV crudo se corrió un segundo script que reduce el dataset a 56 variables seleccionadas y agrega 9 flags temáticos de calidad (precio, operación, tipo de propiedad, superficie, ambientes, coordenadas, expensas, amenities y faltantes críticos), un flag general y un motivo de anomalía en texto — 67 columnas finales. El diseño separa deliberadamente la detección de la corrección: el script no imputa valores, no convierte moneda, no elimina outliers ni

deduplica filas; la única excepción es completar con 0 las 18 variables binarias de amenities cuando no fueron informadas, para poder operarlas. Incluye pruebas automatizadas (parseo de montos en formato argentino, detección de moneda, detección de contradicciones entre título/descripción y el tipo de operación cargado) y una relectura de verificación del archivo final antes de darlo por válido.

Resultado: un dataset propio de 65.846 avisos, verificado y auditable, con evidencia de ejecución (no solo de diseño) tanto del proceso de Web Scraping como del control de calidad posterior, ambos requeridos por la consigna.

7. Limitaciones detectadas y decisiones de diseño pendientes

El propio sistema de control de calidad de la Sección 6 deja a la vista los puntos a resolver antes de avanzar a la Fase 2:

- **Expensas:** 28.166 avisos (42,78%) quedan marcados por el flag de expensas (valores en cero sospechosos, negativos, o muy por encima de los umbrales esperados en ARS/USD). Como las expensas son insumo directo de la Rentabilidad Neta Estimada, se prioriza su revisión antes de calcular ese KPI a escala.
- **Amenities:** 17.701 avisos (26,88%) presentan conflictos entre el tipo de propiedad declarado por MercadoLibre y el inferido a partir del texto de la publicación. Se deberá definir una regla de resolución (por ejemplo, priorizar el campo estructurado sobre el texto libre) antes de usar estos casos en la Tasa de Confort/Amenities.
- **Tipo_Alquiler:** solo el 5,83% de los avisos de alquiler tiene informado si es tradicional o temporario; el 94,17% restante figura como Desconocido. El alcance del proyecto se define como alquiler tradicional (Sección 8), pero hoy no se puede filtrar con total confiabilidad por este campo — se asume tradicional por defecto y se prioriza mejorar esta clasificación (por ejemplo, a partir de señales textuales del título) en la Fase 2.
- **Estado_Inmueble:** presente en el 100% de las filas, pero el 77,30% figura como Desconocido. Es una variable potencialmente valiosa para el modelo de pricing del Índice de Sobre/Subvaluación, pero su baja cobertura real la deja como candidata secundaria hasta enriquecerla.
- **Cobertura desigual en variables secundarias:** campos como Piso (43,25%), Subtipo de Propiedad (23,65%) o Superficie de Balcón (29,74%) tienen cobertura baja porque no aplican a todos los tipos de inmueble (por ejemplo, Piso no aplica a una casa) — no se interpreta como error, pero limita su uso como variable universal en los modelos.

El flag general de anomalías alcanza al 59,52% de los avisos, pero está impulsado casi enteramente por expensas y amenities: los flags de precio, coordenadas y faltantes críticos afectan en conjunto a menos del 3% del dataset. No se interpreta entonces como que más de la mitad del dataset sea inutilizable, aunque sí exige resolver esas dos dimensiones concretas antes de avanzar.

8. Alcance

- **Geográfico:** CABA, todos los barrios.
- **Tipología de producto:** inmuebles residenciales — departamentos, PH y casas (55.582 avisos del dataset actual). Se excluyen oficinas y locales comerciales (10.264 avisos) por no ajustarse al perfil de inversión buy-to-rent residencial del cliente, aunque quedan disponibles en el dataset para un eventual mandato distinto.
- **Temporal:** publicaciones activas al momento del scraping (foto del mercado). Se evaluará repetir el scraping periódicamente para construir un panel temporal.
- **Alquiler tradicional vs. temporario:** se asume alquiler tradicional por defecto, dado que el campo que permitiría distinguirlos tiene cobertura insuficiente hoy (Sección 7); se prioriza resolver esta clasificación antes de reportar KPIs de alquiler a nivel granular.

9. Hoja de ruta

- **Semana 1 (actual):** definición de negocio; scraping de MercadoLibre Inmuebles completado y validado (evidencia en Sección 6), con 65.846 avisos extraídos y procesados a través del pipeline de 9 flags de calidad.
- **Semana 2–3:** resolución de las limitaciones de la Sección 7 (expensas, conflictos de amenities, clasificación de Tipo_Alquiler); filtrado del dataset a los 55.582 avisos residenciales dentro de alcance; preparación del esquema para el enriquecimiento geoespacial.
- **Semana 3–4:** enriquecimiento con fuentes externas (Sección 12) mediante distancia geodésica punto a punto mediante latitud/longitud; cálculo de los KPIs de conectividad, seguridad, salud y educación; cálculo del resto de los KPIs por barrio/tipología, incorporando el modelo de pricing (zona + antigüedad + amenities + entorno geoespacial) como insumo del Índice de Sobre/Subvaluación.
- **Semana 4–5:** análisis exploratorio profundo (descriptivo + diagnóstico), visualizaciones —incluido un mapa de oportunidades—, detección de outliers y cálculo del Score de Oportunidad de Inversión sobre el dataset consolidado.
- **Semana 6+:** modelado predictivo (precio justo) y capa prescriptiva (recomendador de zonas/tipologías y ranking de avisos según presupuesto).

10. Objetivo principal del análisis

Construir un dataset propio, robusto y con cobertura geoespacial del mercado de alquiler y venta de inmuebles residenciales en CABA que permita calcular indicadores de rentabilidad por zona y tipología, incorporar variables de entorno (transporte, seguridad, salud y educación) a nivel de cada aviso individual, identificar oportunidades de inversión buy-to-rent subvaluadas, priorizarlas con un score único y accionable, y sentar las bases de un modelo predictivo de precio justo.

11. Usuario final

Analista/gestor de inversiones del inversor rentista, que usa los reportes, dashboards y el ranking de oportunidades de la consultora para decidir en qué barrio y tipología concentrar la búsqueda activa de propiedades, priorizar en qué avisos concretos invertir su tiempo, y negociar precio de compra con evidencia de mercado verificada.

12. Planificación de integración de fuentes externas (Fase 3)

Fuente externa	Justificación
Polígonos de barrios/comunas de CABA (BA Data / GCBA)	Asignar comuna a cada aviso por sus coordenadas (point-in-polygon) y agregar KPIs a ese nivel.
Ubicación de estaciones de subte, premetro y trenes (BA Data)	Calcular la distancia geodésica de cada aviso a la estación más cercana — insumo directo del KPI de conectividad y de H4.
Mapa del delito / ubicación de comisarías de CABA (BA Data)	Calcular la densidad de hechos en un radio dado — insumo del Índice de Seguridad de Entorno y de H5.
Establecimientos de salud (BA Data)	Distancia al centro de salud más cercano — insumo del KPI de accesibilidad a salud.
Tipo de cambio USD oficial y "blue" (BCRA / series históricas)	Expresar todos los precios en una moneda constante, dado que el dataset mezcla publicaciones en ARS y USD.
Espacios verdes y plazas (BA Data)	Distancia al espacio verde más cercano, proxy de calidad de vida, alimenta a H7
Establecimientos educativos (BA Data)	Calcular densidad de establecimientos educativos en un radio dado — insumo directo del KPI de accesibilidad educativa y de H7.